Relatório de Apresentação: Inteligência Artificial na Saúde – Tecnologia para ampliar a eficiência sem perder o humano

Disciplina: Tecnologias Aplicadas à Saúde

Aluna: Andrisa Santos

1. Introdução

Este relatório apresenta os principais pontos da apresentação realizada pela ER Clinic, healthtech santamariense fundada em 2015 e atuante há 11 anos, intitulada "Inteligência Artificial na Saúde – Tecnologia para ampliar a eficiência sem perder o humano". A apresentação abordou o papel da inteligência artificial (IA) na jornada do paciente, as técnicas empregadas em cada cenário, os cuidados necessários com segurança e regulação e os desafios técnicos enfrentados pela empresa.

Foram ainda mencionados o projeto Treino Scout, que envolve torneios de integração, IA para inferência de categorias, sugestão de treino com base no desempenho dos scouts e scout de atletas, e o tema do custo de aquisição do cliente.

O objetivo deste documento é descrever as técnicas de IA utilizadas e os cenários em que são aplicadas, bem como avaliar a relação entre cada situação e a técnica escolhida.

2. Inteligência Artificial na Saúde

2.1 Papel da IA e divisão de responsabilidades

A apresentação defendeu que a IA não precisa substituir pessoas para transformar profissões. A divisão proposta é a seguinte:

- Tarefas repetitivas: realizadas pela IA.
- Tarefas analíticas: realizadas em conjunto por IA e profissional.
- Relação humana: realizada pelo profissional.

A regra de ouro apresentada estabelece que a IA analisa, organiza, sugere e acelera, enquanto o profissional interpreta, contextualiza, decide e assume a responsabilidade.

2.2 Áreas de atuação

A jornada da saúde foi descrita pelas etapas de pesquisa, prevenção, diagnóstico, tratamento, acompanhamento, gestão e atendimento. Entre as áreas amplas de aplicação foram citadas a pesquisa, a imagem e a documentação clínica. Destacou-se também que o prontuário deve ser guardado por 10 anos.

2.3 Limites, segurança e regulação

Foi enfatizado que IA não é sinônimo de verdade: se erra padrões, pode errar probabilidades e interpretar mal a resposta. Por isso, é necessário criar camadas de segurança, como a configuração de criatividade igual a zero.

A parte clínica deve ser regulada. Foram citados:

- CFM, Resolução nº 2.454/2026, que define níveis de risco;
- LGPD, segundo a qual dados referentes à saúde são dados pessoais sensíveis.

3. Técnicas de IA utilizadas e situações/cenários

A IA é aplicada ao longo da jornada do paciente, nos cenários descritos a seguir.

3.1 Agendamento

3.1.1 Chatbot para WhatsApp

O chatbot realiza atendimento 24 horas e agendamento automático. Atualmente, o recurso é integrado por meio de um parceiro, e a empresa deseja desenvolver o próprio recurso.

Técnicas e tecnologias: LLM e fluxo de agentes; API para integração de terceiros; RAG (consulta aos endpoints da API); Prompt Engineering; processos no N8N.

3.1.2 Alerta de paciente com alto risco de não comparecimento

Com base nos dados da plataforma, o sistema alerta sobre pacientes com alto risco de faltar à consulta. A base é estruturada e considera faltas anteriores, dia e horário da consulta e convênio. Foi ressaltado que a IA vai muito além das LLMs.

A técnica utilizada é o aprendizado de máquina supervisionado, para estimar a probabilidade de o paciente não comparecer a uma consulta agendada:

- Algoritmo: XGBoost, baseado em árvores de decisão combinadas (gradient boosting).
- Tipo de problema: classificação binária com estimativa probabilística; o alvo (target) é comparecer ou não.

- Treinamento supervisionado: cada agendamento histórico é associado a um resultado conhecido (compareceu ou não compareceu).
- Inferência: ao criar um agendamento, o modelo analisa suas características e retorna uma probabilidade de falta, que o sistema apresenta em faixas de risco.
- Importância das variáveis: é preciso selecionar features adequadas, pois elas permitem identificar padrões estatísticos capazes de prever comportamentos futuros. O exemplo apresentado relacionou a venda de sorvete à taxa de afogamento, ilustrando que correlação não implica causalidade.
- Atualização e avaliação do modelo: consideram-se métricas como ROC AUC, Average Precision e Brier Score.

3.2 Transcrição da consulta

O sistema ouve a consulta e preenche automaticamente o prontuário, incluindo evolução, história da doença atual, hipótese diagnóstica, medicações e plano de tratamento. Atualmente, o recurso é integrado com parceiro, e a empresa deseja desenvolver solução própria.

Tecnologias-chave: captura e transmissão de áudio em fragmentos; reconhecimento automático de fala (ASR/STT); LLM e Prompt Engineering para extração e organização das informações clínicas.

Fluxo técnico: (1) captura de áudio; (2) reconhecimento de fala (Speech-to-Text); (3) contextualização clínica; (4) LLM com Prompt Engineering; (5) revisão profissional.

Para a solução própria, o fluxo previsto é: áudio, transcrição, contextualização clínica, LLM, dados estruturados e prontuário. Utilizam-se reconhecimento de fala, base de conhecimento por especialidade com técnicas de RAG (Retrieval-Augmented Generation) e Prompt Engineering.

Desafio de arquitetura: definir onde fazer a transcrição. Duas alternativas foram apresentadas: (1) capturar o áudio e enviá-lo em fragmentos ao servidor; ou (2) transcrever no frontend e enviar somente o texto.

Solução proposta pela autora deste relatório: capturar o áudio e transcrever de forma nativa e natural, como nos áudios do WhatsApp ou nas gravações do Android, de modo que o servidor armazene áudio e texto, retornando somente o texto ao cliente.

3.3 Resumo automático do prontuário

Foram testados modelos de sumarização do Hugging Face, e também foram utilizados modelos comerciais pagos, acessados via OpenRouter.

Tecnologias utilizadas: LLM via OpenRouter; Prompt Engineering; Python e Django; JSON com renderização HTML.

Fluxo do processo: (1) coleta; (2) organização; (3) contextualização; (4) síntese pela LLM; (5) referências navegáveis; (6) atualização incremental.

Principal desafio técnico: foi necessário desenvolver um algoritmo que conhecesse as estruturas do prontuário e soubesse extrair os dados relevantes de cada uma, consolidando tudo em um histórico textual coerente antes de enviá-lo à LLM.

Camadas de cuidado (guardrails): relevância clínica; controle temporal; redução de alucinações; rastreabilidade; renderização segura; controle operacional.

3.4 Exames

A partir da foto ou do PDF do exame, o sistema destaca automaticamente resultados fora dos padrões de referência, organiza as informações e gera um parecer final para apoiar a análise clínica. O histórico do paciente é armazenado, o que permite acompanhar a evolução dos resultados por meio de gráficos. O sistema também identifica a referência da clínica.

Tecnologias utilizadas:

- LLM multimodal via OpenRouter, que recebe os arquivos e interpreta o conteúdo, extraindo informações.
- Processamento de arquivos: PDFs e imagens codificadas em Base64.
- OCR (utilizado anteriormente): PyMuPDF para extração de texto de PDFs e Tesseract OCR para PDFs digitalizados e imagens.
- Python, Django e Celery, que gerenciam o processamento assíncrono.

Fluxo do processo: (1) entrada; (2) preparação; (3) interpretação pela IA; (4) análise individual; (5) parecer geral; (6) persistência.

O sistema interpreta documentos com instruções explícitas (Prompt Engineering), aproveitando a capacidade do modelo de interpretar documentos e imagens. A resposta é um JSON estruturado, convertido em registros individuais.

Camadas de cuidado (guardrails): preservação dos dados; contextualização; controle da resposta; confiabilidade operacional; segurança clínica.

3.5 Copiloto clínico – Córtex

A partir da base privada de conhecimento da clínica, o Córtex localiza protocolos e conteúdos relevantes, organiza informações e sugere condutas, exames e tratamentos com referências. O fluxo é: informação do paciente, conhecimento da clínica, busca, organização e sugestão, e referências, com a decisão final cabendo ao profissional.

Técnica principal: RAG (Retrieval-Augmented Generation). O pipeline de conhecimento compreende: (1) extração; (2) chunking; (3) embeddings, que transformam trechos em vetores numéricos representando características semânticas do conteúdo e reduzem o uso de tokens; (4) base vetorial; (5) recuperação por busca semântica; (6) reranking, que reclassifica os resultados para selecionar os mais pertinentes; (7) geração, com Prompt Engineering.

Tecnologias utilizadas:

- LLM configurável por copiloto, com GPT-5 como exemplo, além do Gemini Flash.
- Embeddings: OpenAI text-embedding-3-small, para codificação do texto em vetores.
- Banco vetorial: Pinecone, com busca por similaridade semântica.
- Reranking: Cohere Rerank, que refina a seleção dos trechos recuperados.
- Backend: API REST em Django, com processamento assíncrono via Celery e Redis, integrada à plataforma ERClinic por API.

Guardrails e rastreabilidade: base privada; respostas fundamentadas; controle de conteúdo; saída estruturada; rastreabilidade.

Principal desafio: recuperar os trechos certos, fornecer contexto suficiente, evitar informações sem sustentação documental e avaliar se a resposta realmente corresponde às fontes consultadas.

4. Avaliação da relação entre situação/cenário e técnica de IA

A tabela a seguir sintetiza a relação entre cada cenário e a técnica empregada.

Cenário	Técnica principal	Natureza da tarefa
Chatbot de agendamento	LLM, fluxo de agentes, RAG, Prompt Engineering, N8N	Repetitiva
Risco de não comparecimento	Machine Learning supervisionado (XGBoost)	Analítica
Transcrição da consulta	ASR/STT, LLM, Prompt Engineering, RAG	Repetitiva, com revisão profissional
Resumo do prontuário	LLM via OpenRouter, Prompt Engineering	Analítica
Exames	LLM multimodal, Prompt Engineering (OCR anteriormente)	Analítica

Cenário	Técnica principal	Natureza da tarefa
Copiloto clínico (Córtex)	RAG com embeddings, base vetorial e reranking	Analítica

4.1 Agendamento por chatbot

O atendimento 24 horas e o agendamento automático correspondem a tarefas repetitivas, categoria que a apresentação atribuiu à IA. O uso de LLM e fluxo de agentes é coerente com a necessidade de dialogar com o paciente, enquanto o RAG sobre os endpoints da API permite que o chatbot consulte as informações da plataforma. A principal limitação observada é a dependência atual de um parceiro, já que a empresa deseja desenvolver o recurso por conta própria.

4.2 Previsão de não comparecimento

Este cenário é o que melhor ilustra a tese de que a IA vai além das LLMs. O problema envolve dados estruturados (faltas anteriores, dia e horário, convênio) e um desfecho binário conhecido (compareceu ou não), o que se ajusta ao aprendizado supervisionado com classificação binária. O XGBoost, baseado em árvores de decisão combinadas, retorna uma probabilidade apresentada em faixas de risco, o que se adequa à finalidade de alertar a equipe. O uso de métricas como ROC AUC, Average Precision e Brier Score demonstra preocupação com a avaliação contínua do modelo. A observação sobre correlação e causalidade reforça que a escolha das features exige critério, pois o modelo identifica padrões estatísticos, e não relações causais.

4.3 Transcrição da consulta

A combinação de reconhecimento de fala e LLM com Prompt Engineering responde a duas necessidades distintas: converter áudio em texto e transformar o texto em dados clínicos estruturados. A inclusão da etapa de revisão profissional no fluxo está alinhada à regra de ouro, segundo a qual o profissional interpreta, decide e assume a responsabilidade. A discussão arquitetural sobre onde transcrever evidencia que a escolha da técnica depende também de decisões de infraestrutura; a solução proposta (transcrição nativa, com o servidor armazenando áudio e texto e devolvendo apenas o texto) busca equilibrar a simplicidade para o usuário com a guarda das informações.

4.4 Resumo do prontuário

A sumarização por LLM é adequada para consolidar históricos extensos. O relato de que foi necessário desenvolver um algoritmo próprio para extrair dados relevantes das estruturas do prontuário indica que o uso da LLM isolada não bastaria, sendo necessária

uma etapa prévia de preparação dos dados. Os guardrails de relevância clínica, controle temporal, redução de alucinações e rastreabilidade respondem diretamente ao alerta de que a IA não é sinônimo de verdade.

4.5 Exames

A mudança de uma abordagem baseada em OCR (PyMuPDF e Tesseract) para uma LLM multimodal simplifica o processamento, pois o mesmo modelo recebe o arquivo e interpreta o conteúdo. A saída em JSON estruturado, convertida em registros individuais, permite armazenar o histórico e gerar gráficos de evolução. O uso de Celery para o processamento assíncrono é compatível com o tempo de análise de arquivos. Os guardrails de segurança clínica e controle da resposta mantêm o resultado como apoio à análise, e não como decisão final.

4.6 Copiloto clínico (Córtex)

O RAG é a técnica mais adequada a este cenário porque o objetivo é que as respostas se baseiem na base privada de conhecimento da clínica, com referências que o profissional possa consultar. Cada etapa do pipeline cumpre uma função: o chunking e os embeddings permitem a busca semântica e reduzem o uso de tokens; o reranking seleciona os trechos mais pertinentes; e a geração por Prompt Engineering produz a resposta fundamentada. O desafio declarado, recuperar os trechos certos e verificar se a resposta corresponde às fontes, mostra que a qualidade do sistema depende da recuperação. Como a decisão permanece com o profissional, o cenário está alinhado à divisão de responsabilidades apresentada.

4.7 Avaliação geral

De modo geral, observa-se coerência entre a natureza de cada tarefa e a técnica empregada: tarefas repetitivas são atendidas por LLM e fluxos automatizados; tarefas analíticas combinam IA e revisão do profissional; e a decisão clínica e a relação humana permanecem com o profissional. A escolha da técnica varia conforme o dado de entrada: aprendizado supervisionado para dados estruturados, reconhecimento de fala para áudio, LLM multimodal para documentos e imagens, e RAG para consulta a bases de conhecimento.

Os guardrails descritos em cada cenário, a rastreabilidade das respostas e a presença do profissional como responsável final estão em consonância com os cuidados destacados na apresentação: a IA não é sinônimo de verdade, a parte clínica deve ser regulada (Resolução CFM nº 2.454/2026) e os dados de saúde são dados pessoais sensíveis (LGPD). Como ponto de atenção comum, destaca-se a dependência de parceiros e de serviços externos em alguns recursos, que a empresa pretende reduzir com o desenvolvimento de soluções próprias.

5. Conclusão

A apresentação da ER Clinic demonstrou que a IA pode ser aplicada em diferentes etapas da jornada do paciente, com técnicas distintas escolhidas conforme o tipo de dado e a natureza da tarefa. O princípio que orienta todos os cenários é o de ampliar a eficiência sem perder o humano: a IA analisa, organiza, sugere e acelera, e o profissional interpreta, contextualiza, decide e assume a responsabilidade.